

# Application of GLM Advancements to Non-Life Insurance Pricing

Leonardo Stincone

Università degli Studi di Trieste

11 Maggio 2021



## 1. Il Pricing nelle Assicurazioni Danni

## 2. Modelli Statistici per il Pricing nelle Assicurazioni Danni

- Modelli Lineari Generalizzati (GLM)

- Modelli Additivi Generalizzati (GAM)

- Stimatori Shrinkage per i GLM

- Stimatori Bayesiani per i GLM

- Algoritmi di Machine Learning

- Confronto tra i modelli

## 3. Applicazione Pratica



## 1. Il Pricing nelle Assicurazioni Danni

## 2. Modelli Statistici per il Pricing nelle Assicurazioni Danni

Modelli Lineari Generalizzati (GLM)

Modelli Additivi Generalizzati (GAM)

Stimatori Shrinkage per i GLM

Stimatori Bayesiani per i GLM

Algoritmi di Machine Learning

Confronto tra i modelli


## 3. Applicazione Pratica



## Contratto di Assicurazione, Art. 1882, Codice Civile Italiano

L'assicurazione è il contratto col quale l'**assicuratore**, verso il pagamento di un **premio**, si obbliga a rivalere l'**assicurato**, entro i limiti convenuti,

- ① del **danno** ad esso prodotto da un **sinistro**,
- ② ovvero a pagare un **capitale** o una **rendita** al verificarsi di un **evento** attinente alla **vita umana**.



## Distribuzione composta

Assumiamo che:

- 1  $\forall n > 0, Z_1|N = n, Z_2|N = n, \dots, Z_n|N = n$  siano i.i.d.;
- 2 la distribuzione di  $Z_i|N = n, i \leq n$  non dipenda da  $n$ .

Sotto queste ipotesi diciamo che:


$$S = \begin{cases} 0 & \text{if } N = 0 \\ \sum_{i=1}^N Z_i & \text{if } N > 0 \end{cases}$$

ha distribuzione composta.

## Proprietà



$$E(S) = E(N)E(Z)$$



## Distribuzione composta

Assumiamo che:

- ①  $\forall n > 0, Z_1|N = n, Z_2|N = n, \dots, Z_n|N = n$  siano i.i.d.;
- ② la distribuzione di  $Z_i|N = n, i \leq n$  non dipenda da  $n$ .

Sotto queste ipotesi diciamo che:


$$S = \begin{cases} 0 & \text{if } N = 0 \\ \sum_{i=1}^N Z_i & \text{if } N > 0 \end{cases}$$

ha distribuzione composta.

## Proprietà



$$E(S) = E(N)E(Z)$$



## Distribuzione composta

Assumiamo che:


- ①  $\forall n > 0, Z_1|N = n, Z_2|N = n, \dots, Z_n|N = n$  siano i.i.d.;
- ② la distribuzione di  $Z_i|N = n, i \leq n$  non dipenda da  $n$ .

Sotto queste ipotesi diciamo che:

$$S = \begin{cases} 0 & \text{if } N = 0 \\ \sum_{i=1}^N Z_i & \text{if } N > 0 \end{cases}$$

ha distribuzione composta.

## Proprietà



$$E(S) = E(N)E(Z)$$

## Variabili esplicative

Possibili variabili esplicative per il pricing delle assicurazioni motor:

- Informazioni sul veicolo assicurato;
- Informazioni generiche sull'assicurato;
- Informazioni assicurative sull'assicurato;
- Opzioni della polizza assicurativa;
- Informazioni sull'assicurato in quanto cliente;
- Dati telematici.

Queste variabili possono essere codificate come un vettore di numeri reali:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip}) \in \mathcal{X} \subseteq \mathbb{R}^p$$

## Regola di Pricing

Una *Regola di Pricing* è una funzione  $f(\cdot)$  che da una  $\mathbf{x}_i \in \mathcal{X}$  restituisce un prezzo  $P_i$ :

$$\begin{aligned} f : \mathcal{X} &\longrightarrow \mathbb{R}_+ \\ \mathbf{x}_i &\longmapsto P_i \end{aligned}$$

## Modellare una variabile risposta

Modellare una variabile risposta  $Y_i$  significa stimare una funzione  $r(\cdot)$  che da una  $\mathbf{x}_i \in \mathcal{X}$  restituisce la distribuzione di  $Y_i$  o alcuni suoi momenti:

$$\begin{aligned} r : \mathcal{X} &\longrightarrow \mathcal{C} \\ \mathbf{x}_i &\longmapsto F_{Y_i}, E(Y_i), Var(Y_i) \end{aligned}$$



## Variabili esplicative

Possibili variabili esplicative per il pricing delle assicurazioni motor:

- Informazioni sul veicolo assicurato;
- Informazioni generiche sull'assicurato;
- Informazioni assicurative sull'assicurato;
- Opzioni della polizza assicurativa;
- Informazioni sull'assicurato in quanto cliente;
- Dati telematici.

Queste variabili possono essere codificate come un vettore di numeri reali:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip}) \in \mathcal{X} \subseteq \mathbb{R}^p$$

## Regola di Pricing

Una *Regola di Pricing* è una funzione  $f(\cdot)$  che da una  $\mathbf{x}_i \in \mathcal{X}$  restituisce un prezzo  $P_i$ :

$$\begin{array}{ccc} f : & \mathcal{X} & \longrightarrow R_+ \\ & \mathbf{x}_i & \longmapsto P_i \end{array}$$


## Modellare una variabile risposta

*Modellare una variabile risposta*  $Y_i$  significa stimare una funzione  $r(\cdot)$  che da una  $\mathbf{x}_i \in \mathcal{X}$  restituisce la distribuzione di  $Y_i$  o alcuni suoi momenti:

$$\begin{array}{ccc} r : & \mathcal{X} & \longrightarrow \mathcal{C} \\ & \mathbf{x}_i & \longmapsto F_{Y_i}, E(Y_i), Var(Y_i) \end{array}$$


## Distribuzione di Poisson

$$p_N(n) = P(N = n) = e^{-\lambda} \frac{\lambda^n}{n!}, \quad \lambda > 0$$



## Distribuzione Gamma

$$f_Z(z) = \frac{\rho^\alpha}{\Gamma(\alpha)} z^{\alpha-1} e^{-\rho z}, \quad \alpha > 0, \rho > 0$$



## Definizione di Premio

$$P_i^{(\text{risk})} = E(S_i)$$

$$P_i^{(\text{tech})} = E(S_i) + \text{Expenses}_i$$

Altri Caricamenti  
Vincoli Normativi  
Commercializzazioni

$$P_i^{(\text{tariff})}$$

$$P_i^{(\text{offer})} = P_i^{(\text{tariff})} - \text{Discount}_i$$

## Ottimizzazione del Prezzo

Si basa su

- 1 Pricing Tecnico
- 2 Aspettativa del Cliente
  - ▶ New Business: *Probabilità di Conversion*
  - ▶ Rinnovi: *Probabilità di Retention*
- 3 Strategia di Business
  - ▶ *Lifetime value*
  - ▶ Profitti/crescita

## Definizione di Premio

$$P_i^{(\text{risk})} = E(S_i)$$

$$P_i^{(\text{tech})} = E(S_i) + \text{Expenses}_i$$

Altri Caricamenti  
Vincoli Normativi  
Commercializzazioni

$$P_i^{(\text{tariff})}$$

$$P_i^{(\text{offer})} = P_i^{(\text{tariff})} - \text{Discount}_i$$

## Ottimizzazione del Prezzo

Si basa su

- 1 Pricing Tecnico
- 2 Aspettativa del Cliente
  - ▶ New Business: *Probabilità di Conversion*
  - ▶ Rinnovi: *Probabilità di Retention*
- 3 Strategia di Business
  - ▶ *Lifetime value*
  - ▶ Profitti/crescita

## 1. Il Pricing nelle Assicurazioni Danni

## 2. Modelli Statistici per il Pricing nelle Assicurazioni Danni

- Modelli Lineari Generalizzati (GLM)

- Modelli Additivi Generalizzati (GAM)

- Stimatori Shrinkage per i GLM

- Stimatori Bayesiani per i GLM

- Algoritmi di Machine Learning

- Confronto tra i modelli

## 3. Applicazione Pratica



## Modelli Lineari Generalizzati (GLM)

Dato  $\mathcal{D} = \{(\mathbf{x}_1, \omega_1, y_1), \dots, (\mathbf{x}_n, \omega_n, y_n)\}$

con  $\mathbf{y} = (y_1, \dots, y_n)^t$  realizzazione di  $\mathbf{Y} = (Y_1, \dots, Y_n)^t$ .

Assumiamo che:

- 1  $\mathbf{Y} = (Y_1, \dots, Y_n)^t$  siano indipendenti con distribuzione appartenente a una stessa famiglia esponenziale lineare:

$$f(y_i; \theta_i, \phi, \omega_i) = \exp \left\{ \frac{\omega_i}{\phi} [y_i \theta_i - b(\theta_i)] \right\} c(y_i, \phi, \omega_i), \quad y_i \in \mathcal{Y} \subseteq \mathbb{R}$$

- 2  $\mathbf{x}_i = (1, x_{i1}, \dots, x_{ip})^t$  agisca su  $Y_i$  tramite il predittore lineare  $\eta_i$

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}$$

- 3  $\eta_i$  sia legato a  $\mu_i = E(Y_i)$  tramite la funzione legame  $g(\cdot)$

$$g(\mu_i) = \eta_i = \mathbf{x}_i^t \boldsymbol{\beta}$$



## Stima di massima verosimiglianza

Data la funzione di verosimiglianza

$$\begin{aligned} L : \mathbb{R}^{p+1} \times \Lambda &\longrightarrow [0, +\infty[ \\ (\boldsymbol{\beta}, \phi) &\longmapsto f_{\mathbf{Y}}(\mathbf{y}; \boldsymbol{\theta}, \phi) \end{aligned}$$

La stima di massima verosimiglianza è:

$$\hat{\boldsymbol{\beta}} = \arg \max_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} L(\boldsymbol{\beta}, \phi; \mathbf{y})$$

## Devianza

La devianza è

$$D(\hat{\boldsymbol{\beta}}, \mathbf{y}) = -2\phi \left( \ell(\hat{\boldsymbol{\beta}}, \phi; \mathbf{y}) - \ell_s(\boldsymbol{\beta}^*, \phi; \mathbf{y}) \right)$$

dove  $\ell(\hat{\boldsymbol{\beta}}, \phi; \mathbf{y}) = \log L(\hat{\boldsymbol{\beta}}, \phi; \mathbf{y})$   
e  $\boldsymbol{\beta}^*$  sono i parametri del modello saturo.

La stima di massima verosimiglianza può essere ottenuta come:

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} D(\boldsymbol{\beta}, \mathbf{y})$$



## Stima di massima verosimiglianza

Data la funzione di verosimiglianza

$$\begin{aligned} L : \mathbb{R}^{p+1} \times \Lambda &\longrightarrow [0, +\infty[ \\ (\boldsymbol{\beta}, \phi) &\longmapsto f_{\mathbf{Y}}(\mathbf{y}; \boldsymbol{\theta}, \phi) \end{aligned}$$

La stima di massima verosimiglianza è:

$$\hat{\boldsymbol{\beta}} = \arg \max_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} L(\boldsymbol{\beta}, \phi; \mathbf{y})$$

## Devianza

La devianza è

$$D(\hat{\boldsymbol{\beta}}, \mathbf{y}) = -2\phi \left( \ell(\hat{\boldsymbol{\beta}}, \phi; \mathbf{y}) - \ell_S(\boldsymbol{\beta}^*, \phi; \mathbf{y}) \right)$$

dove  $\ell(\hat{\boldsymbol{\beta}}, \phi; \mathbf{y}) = \log L(\hat{\boldsymbol{\beta}}, \phi; \mathbf{y})$   
e  $\boldsymbol{\beta}^*$  sono i parametri del modello saturo.


La stima di massima verosimiglianza può essere ottenuta come:

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} D(\boldsymbol{\beta}, \mathbf{y})$$




# Effetto delle variabili in un GLM


Quantitativa




Qualitativa



Quantitativa e qualitativa  
senza interazione




Quantitativa e qualitativa  
con interazione




# Variabili quantitative ed effetti non lineari


Polinomiale di grado 2




Polinomiale di grado 4



Piece-wise lineare




Piece-wise polinomiale di grado 2




# Funzione Legame e risposta


Normale - identità




Binomiale - logit



Poisson - log




Gamma - log




# Grafici per visualizzare l'effetto delle variabili


Nessun effetto - non raggruppati




Effetto positivo - non raggruppati



Nessun effetto - raggruppati



Effetto positivo - raggruppati



## Criteri per la selezione delle variabili

- Visualizzazione
- Test di verifica di ipotesi

$$\begin{cases} H_0 : \beta_{j_k} = 0 \quad \forall k \in \{1, 2, \dots, s\} \\ H_1 : \exists k : \beta_{j_k} \neq 0 \end{cases}$$

- Criteri di informazione

$$AIC = -2\ell(\beta) + 2(p + 1)$$

$$BIC = -2\ell(\beta) + \log(n)(p + 1)$$

- Divisione del dataset tra training set e test set
- Cross validation

$\implies$  Algoritmi stepwise



1. Il Pricing nelle Assicurazioni Danni

2. Modelli Statistici per il Pricing nelle Assicurazioni Danni

Modelli Lineari Generalizzati (GLM)

**Modelli Additivi Generalizzati (GAM)**

Stimatori Shrinkage per i GLM

Stimatori Bayesiani per i GLM

Algoritmi di Machine Learning

Confronto tra i modelli

3. Applicazione Pratica



## Modelli Additivi Generalizzati (GAM)

- ❶ Variabile risposta  $\mathbf{Y}$  come GLM;
- ❷ Predittore lineare

$$\eta_i = \mathbf{x}_i^t \boldsymbol{\beta} + \sum_{l=1}^q f_l(z_{i,l}), \quad i \in \{1, 2, \dots, n\}$$

con  $f_l(\cdot)$  spline cubica;


- ❸ Funzione legame  $g(\cdot)$  come GLM.

## Stima di Massima Verosimiglianza con Penalizzazione


$$\hat{\mathbf{f}} = \arg \min_{\mathbf{f}} \left\{ D(\mathbf{f}, \mathbf{y}) + \sum_{l=1}^q \lambda_l \int_{a_l}^{b_l} (f_l''(x_l))^2 dx \right\}$$

con  $\lambda_1, \lambda_2, \dots, \lambda_q$  iperparametri di smoothing.


$\lambda = 0$




$\lambda = 10$



$\lambda = 10^3$



$\lambda = 10^6$





## 1. Il Pricing nelle Assicurazioni Danni

## 2. Modelli Statistici per il Pricing nelle Assicurazioni Danni

Modelli Lineari Generalizzati (GLM)

Modelli Additivi Generalizzati (GAM)

**Stimatori Shrinkage per i GLM**

Stimatori Bayesiani per i GLM

Algoritmi di Machine Learning


Confronto tra i modelli

## 3. Applicazione Pratica



## Scomposizione dello scarto quadratico medio (MSE)

$$MSE(\tilde{\beta}_j) \stackrel{\text{def}}{=} E\left((\tilde{\beta}_j - \beta_j)^2\right) = \underbrace{\left(E(\tilde{\beta}_j) - \beta_j\right)^2}_{\text{Bias}^2} + \underbrace{\text{Var}(\tilde{\beta}_j)}_{\text{Variance}}$$



## Stima di Massima Verosimiglianza con Penalizzazione

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \left\{ D(\beta, \mathbf{y}) + \lambda \sum_{j=1}^p \beta_j^2 \right\}$$


con

- $\lambda \geq 0$  iperparametro di penalizzazione


Modello sottostante: GLM

# Regressione Ridge: esempio


$\lambda = 0$





$\lambda = 0.1$



$\lambda = 1$



$\lambda = 10$



## Stima di Massima Verosimiglianza con Penalizzazione

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \left\{ D(\beta, \mathbf{y}) + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

con


- $\lambda \geq 0$  iperparametro di penalizzazione

Modello sottostante: GLM




# Regressione LASSO: esempio


$\lambda = 0$





$\lambda = 0.1$



$\lambda = 1$



$\lambda = 10$



## Stima di Massima Verosimiglianza con Penalizzazione

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \left\{ D(\beta, \mathbf{y}) + \lambda \sum_{j=1}^p (\alpha |\beta_j| + (1 - \alpha) |\beta_j|^2) \right\}$$

dove

- $\lambda \geq 0$  iperparametro di penalizzazione
- $\alpha \in [0, 1]$  iperparametro che determina il peso della penalizzazione LASSO
  - ▶  $\alpha = 0 \implies$  Regressione Ridge
  - ▶  $\alpha = 1 \implies$  Regressione LASSO

Modello sottostante: GLM



1. Il Pricing nelle Assicurazioni Danni

2. Modelli Statistici per il Pricing nelle Assicurazioni Danni

Modelli Lineari Generalizzati (GLM)

Modelli Additivi Generalizzati (GAM)

Stimatori Shrinkage per i GLM

**Stimatori Bayesiani per i GLM**

Algoritmi di Machine Learning

Confronto tra i modelli

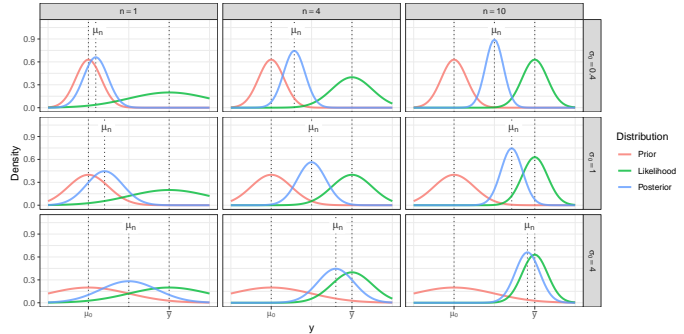
3. Applicazione Pratica





## Teorema di Bayes

$$\pi(\theta|\mathbf{y}) = \frac{p(\mathbf{y}|\theta)\pi(\theta)}{p(\mathbf{y})}$$



## Stima di Massima Verosimiglianza

$$\begin{aligned}\hat{\beta}^{ML} &= \arg \max_{\beta \in \mathbb{R}^{p+1}} L(\beta, \phi \mid \mathbf{y}) \\ &= \arg \max_{\beta \in \mathbb{R}^{p+1}} \ell(\beta, \phi \mid \mathbf{y}) \\ &= \arg \min_{\beta \in \mathbb{R}^{p+1}} D(\beta, \mathbf{y})\end{aligned}$$

## Stima di Massimo a Posteriori

$$\begin{aligned}\hat{\beta}^{MAP} &= \arg \max_{\beta \in \mathbb{R}^{p+1}} \pi(\beta, \phi \mid \mathbf{y}) \\ &= \arg \max_{\beta \in \mathbb{R}^{p+1}} \{L(\beta, \phi \mid \mathbf{y}) \pi(\beta)\} \\ &= \arg \max_{\beta \in \mathbb{R}^{p+1}} \{\ell(\beta, \phi \mid \mathbf{y}) + \log(\pi(\beta))\} \\ &= \arg \min_{\beta \in \mathbb{R}^{p+1}} \{D(\beta, \mathbf{y}) - 2\phi \log(\pi(\beta))\}\end{aligned}$$

## Stima di Massima Verosimiglianza


$$\begin{aligned}\hat{\beta}^{ML} &= \arg \max_{\beta \in \mathbb{R}^{p+1}} L(\beta, \phi \mid \mathbf{y}) \\ &= \arg \max_{\beta \in \mathbb{R}^{p+1}} \ell(\beta, \phi \mid \mathbf{y}) \\ &= \arg \min_{\beta \in \mathbb{R}^{p+1}} D(\beta, \mathbf{y})\end{aligned}$$

## Stima di Massimo a Posteriori


$$\begin{aligned}\hat{\beta}^{MAP} &= \arg \max_{\beta \in \mathbb{R}^{p+1}} \pi(\beta, \phi \mid \mathbf{y}) \\ &= \arg \max_{\beta \in \mathbb{R}^{p+1}} \{L(\beta, \phi \mid \mathbf{y}) \pi(\beta)\} \\ &= \arg \max_{\beta \in \mathbb{R}^{p+1}} \{\ell(\beta, \phi \mid \mathbf{y}) + \log(\pi(\beta))\} \\ &= \arg \min_{\beta \in \mathbb{R}^{p+1}} \{D(\beta, \mathbf{y}) - 2\phi \log(\pi(\beta))\}\end{aligned}$$

# Regressione Ridge e LASSO come Stimatori Bayesiani


Distribuzione Normale  
⇒ Regressione Ridge



Distribuzione di Laplace  
⇒ Regressione LASSO



Distribuzione intermedia  
⇒ Elastic Net



## Altre distribuzioni a priori

- Diverse varianze a priori

$$\beta_j \sim \mathcal{N}(0, \sigma_j^2)$$

- Diverse medie a priori

$$\beta_j \sim \mathcal{N}(\beta_{j0}, \sigma_j^2)$$

- Altre distribuzioni a priori

$$\pi(\beta_j) = \begin{cases} \frac{\sqrt{2}}{\sqrt{\pi}\sigma} e^{-\frac{1}{2\sigma^2}\beta_j^2} & \text{if } \beta_j \geq 0 \\ 0 & \text{altrimenti} \end{cases}$$

## Vantaggi stimatori Bayesiani

- Introduzione informazione esterna ai dati con una robusta metodologia statistica

- Rimpiazzamento degli offset  
Scelgo  $\sigma_j^2$  tale che  $\hat{\beta}^{MAP} = \hat{\beta}^{\text{offset}}$

- ▶ Ho accortezza di quanto è forte la correzione applicata
- ▶ Se cambio qualche altro parametro e rifitto il modello, in automatico  $\hat{\beta}^{MAP}$  viene ristimato

## Altre distribuzioni a priori

- Diverse varianze a priori

$$\beta_j \sim \mathcal{N}(0, \sigma_j^2)$$

- Diverse medie a priori

$$\beta_j \sim \mathcal{N}(\beta_{j0}, \sigma_j^2)$$

- Altre distribuzioni a priori

$$\pi(\beta_j) = \begin{cases} \frac{\sqrt{2}}{\sqrt{\pi}\sigma} e^{-\frac{1}{2\sigma^2}\beta_j^2} & \text{if } \beta_j \geq 0 \\ 0 & \text{altrimenti} \end{cases}$$

## Vantaggi stimatori Bayesiani

- Introduzione informazione esterna ai dati con una robusta metodologia statistica

- Rimpiazzamento degli offset

Scelgo  $\sigma_j^2$  tale che  $\hat{\beta}^{MAP} = \hat{\beta}^{\text{offset}}$

- ▶ Ho accortezza di quanto è forte la correzione applicata
- ▶ Se cambio qualche altro parametro e rifitto il modello, in automatico  $\hat{\beta}^{MAP}$  viene ristimato

1. Il Pricing nelle Assicurazioni Danni

2. Modelli Statistici per il Pricing nelle Assicurazioni Danni

Modelli Lineari Generalizzati (GLM)

Modelli Additivi Generalizzati (GAM)

Stimatori Shrinkage per i GLM

Stimatori Bayesiani per i GLM

Algoritmi di Machine Learning

Confronto tra i modelli

3. Applicazione Pratica



## Modelli di Machine Learning

- Gradient Boosting Machine (GBM)
- Random Forest (RF)
- Neural Network (NN)
- Altri ...

## Caratteristiche

- Funzione di regressione con minime assunzioni

$$E(Y_i) = f(x_{i1}, \dots, x_{ip})$$

- Sofisticati algoritmi per prevenire l'overfitting



## Modelli di Machine Learning

- Gradient Boosting Machine (GBM)
- Random Forest (RF)
- Neural Network (NN)
- Altri ...

## Caratteristiche

- Funzione di regressione con minime assunzioni

$$E(Y_i) = \mathbf{f}(x_{i1}, \dots, x_{ip})$$

- Sofisticati algoritmi per prevenire l'overfitting

## 1. Il Pricing nelle Assicurazioni Danni

## 2. Modelli Statistici per il Pricing nelle Assicurazioni Danni

Modelli Lineari Generalizzati (GLM)

Modelli Additivi Generalizzati (GAM)

Stimatori Shrinkage per i GLM

Stimatori Bayesiani per i GLM

Algoritmi di Machine Learning

Confronto tra i modelli

## 3. Applicazione Pratica



	GLM Classici	GBM/RF/NN	GLM Advancements
Interpretabilità	★★★★	★★★☆☆	★★★★
Controllo delle variabili	★★★★	★★★☆☆	★★★★
Utilizzo di informazioni esterne	★★★★☆	★★★☆☆	★★★★
Automazione e scalabilità	★★★☆☆	★★★★	★★★★☆
Flessibilità	★★★☆☆	★★★★	★★★★☆

# L'importanza del Controllo delle Variabili nel Pricing

## Il pricing si basa su

- Osservazioni sul portafoglio passato
- Assunzioni sul portafoglio futuro

### Necessità tecniche per il controllo delle variabili

- Dati non rappresentativi del portafoglio futuro
- Stime con alta varianza su certi cluster

### Necessità commerciali per il controllo delle variabili

- Vincoli normativi
- Pricing opzioni
- Aspettative del cliente
- Strategia di business



## Il pricing si basa su

- Osservazioni sul portafoglio passato
- Assunzioni sul portafoglio futuro

## Necessità tecniche per il controllo delle variabili

- Dati non rappresentativi del portafoglio futuro
- Stime con alta varianza su certi cluster

## Necessità commerciali per il controllo delle variabili

- Vincoli normativi
- Pricing opzioni
- Aspettative del cliente
- Strategia di business

1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
  - Modelli Lineari Generalizzati (GLM)
  - Modelli Additivi Generalizzati (GAM)
  - Stimatori Shrinkage per i GLM
  - Stimatori Bayesiani per i GLM
  - Algoritmi di Machine Learning
  - Confronto tra i modelli
3. Applicazione Pratica



## Origine del Dataset

Portafoglio RCA costituito da polizze di una provincia italiana nel periodo 2014-2019

Set	Osservazioni	Esposizione (rischi anno)	Assicurati	Esposizione per Assicurato	Numero Sinistri	Frequenza Sinistri
Train	227 226	107 998.4	27 346	3.95	4 823	0.045
Test	56 603	26 806.3	6 824	3.93	1 131	0.042
Tot	283 829	134 804.7	34 170	3.95	5 954	0.044

Descrizione	Numero di variabili per categoria
Informazioni sul veicolo assicurato	12
Informazioni generiche sull'assicurato	14
Informazioni assicurative sull'assicurato	9
Opzioni della polizza assicurativa	11
Informazioni sull'assicurato in quanto cliente	2
Dati telematici	4
<b>Totale</b>	<b>52</b>



## Modelli considerati

Id	Model
Mod1	GLM Tot
Mod2	Elastic Net Tot
Mod3	Ridge Tot
Mod4	GLM AIC
Mod5	Elastic Net AIC
Mod6	GAM AIC
Mod7	GBM Tot

## Valutazione

### Metrica di confronto:

Devianza della distribuzione di Poisson  
calcolata sul test set

$$D(\hat{\beta}, \mathbf{y}) = 2 \sum_{i=1}^n \left\{ y_i \log \left( \frac{y_i}{\hat{\mu}_i} \right) - (y_i - \hat{\mu}_i) \right\}$$

## Modelli considerati

Id	Model
Mod1	GLM Tot
Mod2	Elastic Net Tot
Mod3	Ridge Tot
Mod4	GLM AIC
Mod5	Elastic Net AIC
Mod6	GAM AIC
Mod7	GBM Tot


## Valutazione


### Metrica di confronto:

Devianza della distribuzione di Poisson  
calcolata sul test set

$$D(\hat{\boldsymbol{\beta}}, \mathbf{y}) = 2 \sum_{i=1}^n \left\{ y_i \log \left( \frac{y_i}{\hat{\mu}_i} \right) - (y_i - \hat{\mu}_i) \right\}$$

# Elastic Net: Tuning degli Iperparametri





Id	Model	Test Deviance	Time	$\alpha$	$\lambda$
Mod1	GLM Tot	8 458.147	2.7s	0	0
Mod2	Elastic Net Tot	8 458.024	1h 30m	0.06	2.01e-04
Mod3	<b>Ridge Tot</b>	<b>8 457.465</b>	1h 30m	0	4.64e-04
Mod4	GLM AIC	8 458.023	7h 27m	0	0
Mod5	Elastic Net AIC	8 458.236	8h 54m	0	1.63e-05
Mod6	GAM AIC	9 728.570	7h 45m	0	0
Mod7	GBM Tot	8 504.178	2h 30m		

## Possibili Sviluppi

- Utilizzare diverse distribuzioni a priori per i diversi  $\beta_j$
- Considerare interazioni
- Ulteriore esplorazione sui GAM
- Modelli geografici
- Implementare i modelli su dataset più grandi con adeguate implementazioni informatiche


Grazie per l'attenzione



# Backup




# Elastic Net AIC: Tuning degli Iperparametri






# Elastic Net AIC: Tuning degli Iperparametri



# Confronto tra i coefficienti



model	value
GLM Tot	-6.447
EN Tot	0.000
Ridge Tot	-0.003
GLM AIC	-6.574
EN AIC	-0.095

GLM Tot	Elastic Net Tot	GLM AIC	n	
$\neq 0$	$\neq 0$	$\neq 0$	51	121
$\neq 0$	$\neq 0$	0	48	
$\neq 0$	0	$\neq 0$	6	
$\neq 0$	0	0	16	
0	$\neq 0$	0	23	38
0	0	0	15	