

Application of GLM Advancements to Non-Life Insurance Pricing

Leonardo Stincone

Università degli Studi di Trieste

10 Maggio 2021



1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)
 - Modelli Additivi Generalizzati (GAM)
 - Stimatori Shrinkage per i GLM
 - Stimatori Bayesiani per i GLM
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica



1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)
 - Modelli Additivi Generalizzati (GAM)
 - Stimatori Shrinkage per i GLM
 - Stimatori Bayesiani per i GLM
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica




Contratto di Assicurazione, Art. 1882, Codice Civile Italiano

L'assicurazione è il contratto col quale l'**assicuratore**, verso il pagamento di un **premio**, si obbliga a rivalere l'**assicurato**, entro i limiti convenuti,

- ① del **danno** ad esso prodotto da un **sinistro**,
- ② ovvero a pagare un **capitale** o una **rendita** al verificarsi di un **evento** attinente alla **vita umana**.





Distribuzione composta

Assumiamo che:

- 1 $\forall n > 0, Z_1|N = n, Z_2|N = n, \dots, Z_n|N = n$ siano i.i.d.;
- 2 la distribuzione di $Z_i|N = n, i \leq n$ non dipenda da n .

Sotto queste ipotesi diciamo che:

$$S = \begin{cases} 0 & \text{if } N = 0 \\ \sum_{i=1}^N Z_i & \text{if } N > 0 \end{cases}$$


ha distribuzione composta.

Proprietà



$$E(S) = E(N)E(Z)$$





Distribuzione composta

Assumiamo che:

- ① $\forall n > 0, Z_1|N = n, Z_2|N = n, \dots, Z_n|N = n$ siano i.i.d.;
- ② la distribuzione di $Z_i|N = n, i \leq n$ non dipenda da n .

Sotto queste ipotesi diciamo che:

$$S = \begin{cases} 0 & \text{if } N = 0 \\ \sum_{i=1}^N Z_i & \text{if } N > 0 \end{cases}$$


ha distribuzione composta.

Proprietà



$$E(S) = E(N)E(Z)$$





Distribuzione composta

Assumiamo che:


- ① $\forall n > 0, Z_1|N = n, Z_2|N = n, \dots, Z_n|N = n$ siano i.i.d.;
- ② la distribuzione di $Z_i|N = n, i \leq n$ non dipenda da n .

Sotto queste ipotesi diciamo che:

$$S = \begin{cases} 0 & \text{if } N = 0 \\ \sum_{i=1}^N Z_i & \text{if } N > 0 \end{cases}$$

ha distribuzione composta.

Proprietà



$$E(S) = E(N)E(Z)$$



Variabili esplicative

Possibili variabili esplicative per il pricing delle assicurazioni motor:

- Informazioni sul veicolo assicurato;
- Informazioni generiche sul contraente;
- Informazioni assicurative sul contraente;
- Opzioni sulla polizza assicurativa;
- Dati telematici.

Queste variabili possono essere codificate come un vettore di numeri reali:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip}) \in \mathcal{X} \subseteq \mathbb{R}^p$$

Regola di Pricing

Una *Regola di Pricing* è una funzione $f(\cdot)$ che da una $\mathbf{x}_i \in \mathcal{X}$ restituisce un prezzo P_i :

$$\begin{aligned} f : \mathcal{X} &\longrightarrow R_+ \\ \mathbf{x}_i &\longmapsto P_i \end{aligned}$$

Modellare una variabile risposta

Modellare una variabile risposta Y_i significa stimare una funzione $r(\cdot)$ che da una $\mathbf{x}_i \in \mathcal{X}$ restituisce la distribuzione di Y_i o alcuni suoi momenti:

$$\begin{aligned} r : \mathcal{X} &\longrightarrow \mathcal{C} \\ \mathbf{x}_i &\longmapsto F_{Y_i}, E(Y_i), Var(Y_i) \end{aligned}$$



Variabili esplicative

Possibili variabili esplicative per il pricing delle assicurazioni motor:

- Informazioni sul veicolo assicurato;
- Informazioni generiche sul contraente;
- Informazioni assicurative sul contraente;
- Opzioni sulla polizza assicurativa;
- Dati telematici.

Queste variabili possono essere codificate come un vettore di numeri reali:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip}) \in \mathcal{X} \subseteq \mathbb{R}^p$$

Regola di Pricing

Una *Regola di Pricing* è una funzione $f(\cdot)$ che da una $\mathbf{x}_i \in \mathcal{X}$ restituisce un prezzo P_i :

$$\begin{array}{ccc} f : & \mathcal{X} & \longrightarrow R_+ \\ & \mathbf{x}_i & \longmapsto P_i \end{array}$$

Modellare una variabile risposta


Modellare una variabile risposta Y_i significa stimare una funzione $r(\cdot)$ che da una $\mathbf{x}_i \in \mathcal{X}$ restituisce la distribuzione di Y_i o alcuni suoi momenti:

$$\begin{array}{ccc} r : & \mathcal{X} & \longrightarrow \mathcal{C} \\ & \mathbf{x}_i & \longmapsto F_{Y_i}, E(Y_i), Var(Y_i) \end{array}$$




Distribuzione di Poisson

$$p_N(n) = P(N = n) = e^{-\lambda} \frac{\lambda^n}{n!}, \quad \lambda > 0$$



Distribuzione Gamma

$$f_Z(z) = \frac{\rho^\alpha}{\Gamma(\alpha)} z^{\alpha-1} e^{-\rho z}, \quad \alpha > 0, \rho > 0$$



Definizione di Premio

$$P_i^{(\text{risk})} = E(S_i)$$

$$P_i^{(\text{tech})} = E(S_i) + \text{Expenses}_i$$

Altri Caricamenti
Vincoli Normativi
Commercializzazioni

$$P_i^{(\text{tariff})}$$

$$P_i^{(\text{offer})} = P_i^{(\text{tariff})} - \text{Discount}_i$$

Ottimizzazione del Prezzo

Si basa su

- 1 Pricing Tecnico
- 2 Aspettativa del Cliente
- 3 Strategia di Business

Ulteriori modelli

- New Business: Probabilità di Conversion
- Rinnovi: Probabilità di Retention



Definizione di Premio

$$P_i^{(\text{risk})} = E(S_i)$$

$$P_i^{(\text{tech})} = E(S_i) + \text{Expenses}_i$$

Altri Caricamenti
Vincoli Normativi
Commercializzazioni



$$P_i^{(\text{tariff})}$$

$$P_i^{(\text{offer})} = P_i^{(\text{tariff})} - \text{Discount}_i$$

Ottimizzazione del Prezzo

Si basa su

- 1 Pricing Tecnico
- 2 Aspettativa del Cliente
- 3 Strategia di Business

Ulteriori modelli

- New Business: Probabilità di Conversion
- Rinnovi: Probabilità di Retention



1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)
 - Modelli Additivi Generalizzati (GAM)
 - Stimatori Shrinkage per i GLM
 - Stimatori Bayesiani per i GLM
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica



1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)**
 - Modelli Additivi Generalizzati (GAM)
 - Stimatori Shrinkage per i GLM
 - Stimatori Bayesiani per i GLM
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica



Modelli Lineari Generalizzati (GLM)

Dato $\mathcal{D} = \{(\mathbf{x}_1, \omega_1, y_1), \dots, (\mathbf{x}_n, \omega_n, y_n)\}$

con $\mathbf{y} = (y_1, \dots, y_n)^t$ realizzazione di $\mathbf{Y} = (Y_1, \dots, Y_n)^t$.

Assumiamo che:

- 1 $\mathbf{Y} = (Y_1, \dots, Y_n)^t$ siano indipendenti con distribuzione appartenente a una stessa famiglia esponenziale lineare:

$$f(y_i; \theta_i, \phi, \omega_i) = \exp \left\{ \frac{\omega_i}{\phi} [y_i \theta_i - b(\theta_i)] \right\} c(y_i, \phi, \omega_i), \quad y_i \in \mathcal{Y} \subseteq \mathbb{R}$$

- 2 $\mathbf{x}_i = (1, x_{i1}, \dots, x_{ip})^t$ agisca su Y_i tramite il predittore lineare η_i

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}$$

- 3 η_i sia legato a $\mu_i = E(Y_i)$ tramite la funzione legame $g(\cdot)$

$$g(\mu_i) = \eta_i = \mathbf{x}_i^t \boldsymbol{\beta}$$



Stima di massima verosimiglianza

Data la funzione di verosimiglianza

$$\begin{aligned} L : \mathbb{R}^{p+1} \times \Lambda &\longrightarrow [0, +\infty[\\ (\beta, \phi) &\longmapsto f_Y(\mathbf{y}; \theta, \phi) \end{aligned}$$

La stima di massima verosimiglianza è:

$$\hat{\beta} = \arg \max_{\beta \in \mathbb{R}^{p+1}} L(\beta, \phi; \mathbf{y})$$

Devianza

La devianza è

$$D(\hat{\beta}, \mathbf{y}) = -2\phi \left(\ell(\hat{\beta}, \phi; \mathbf{y}) - \ell_s(\beta^*, \phi; \mathbf{y}) \right)$$

dove $\ell(\hat{\beta}, \phi; \mathbf{y}) = \log L(\hat{\beta}, \phi; \mathbf{y})$
e β^* sono i parametri del modello saturo.

La stima di massima verosimiglianza può essere ottenuta come:

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} D(\beta, \mathbf{y})$$



Stima di massima verosimiglianza

Data la funzione di verosimiglianza

$$\begin{aligned} L : \mathbb{R}^{p+1} \times \Lambda &\longrightarrow [0, +\infty[\\ (\beta, \phi) &\longmapsto f_Y(\mathbf{y}; \theta, \phi) \end{aligned}$$

La stima di massima verosimiglianza è:

$$\hat{\beta} = \arg \max_{\beta \in \mathbb{R}^{p+1}} L(\beta, \phi; \mathbf{y})$$

Devianza

La devianza è

$$D(\hat{\beta}, \mathbf{y}) = -2\phi \left(\ell(\hat{\beta}, \phi; \mathbf{y}) - \ell_S(\beta^*, \phi; \mathbf{y}) \right)$$


dove $\ell(\hat{\beta}, \phi; \mathbf{y}) = \log L(\hat{\beta}, \phi; \mathbf{y})$
e β^* sono i parametri del modello saturo.

La stima di massima verosimiglianza può essere ottenuta come:


$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} D(\beta, \mathbf{y})$$




Effetto delle variabili in un GLM




(a) Quantitativa



(b) Qualitativa




(c) Quantitativa e qualitativa
senza interazione




(d) Quantitativa e qualitativa
con interazione


Variabili quantitative ed effetti non lineari




(a) Polynomial degree 2



(b) Polynomial degree 4




(c) Piece-wise linear




(d) Piece-wise polynomial degree 2


Funzione Legame e risposta




(a) Normal - identity



(b) Binomial - logit




(c) Poisson - log




(d) Gamma - log


Grafici per visualizzare l'effetto delle variabili




(a) No effect - ungrouped



(b) Positive effect - ungrouped



(c) No effect - grouped



(d) Positive effect - grouped

Criteri per la selezione delle variabili

- Visualizzazione
- Test di verifica di ipotesi

$$\begin{cases} H_0 : \beta_{j_k} = 0 \quad \forall k \in \{1, 2, \dots, s\} \\ H_1 : \exists k : \beta_{j_k} \neq 0 \end{cases}$$

- Criteri di informazione

$$AIC = -2\ell(\beta) + 2(p + 1)$$

$$BIC = -2\ell(\beta) + \log(n)(p + 1)$$

- Divisione del dataset tra training set e test set
- Cross validation

⇒ Algoritmi stepwise



1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)
 - Modelli Additivi Generalizzati (GAM)**
 - Stimatori Shrinkage per i GLM
 - Stimatori Bayesiani per i GLM
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica



Modello Additivo Generalizzato (GAM)

- ① Variabile risposta \mathbf{Y} come GLM;
- ② Predittore lineare

$$\eta_i = \mathbf{x}_i^t \boldsymbol{\beta} + \sum_{l=1}^q f_l(z_{i,l}), \quad i \in \{1, 2, \dots, n\}$$

con $f_l(\cdot)$ spline cubica;


- ③ Funzione legame $g(\cdot)$ come GLM.

Stima di Massima Verosimiglianza con Penalizzazione


$$\hat{\mathbf{f}} = \arg \min_{\mathbf{f}} \left\{ D(\mathbf{f}, \mathbf{y}) + \sum_{l=1}^q \lambda_l \int_{a_l}^{b_l} (f_l''(x_l))^2 dx \right\}$$

con $\lambda_1, \lambda_2, \dots, \lambda_q$ iperparametri di smoothing.







(a) $\lambda = 0$



(b) $\lambda = 10$



(c) $\lambda = 10^3$




(d) $\lambda = 10^6$

1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)
 - Modelli Additivi Generalizzati (GAM)
 - Stimatori Shrinkage per i GLM**
 - Stimatori Bayesiani per i GLM
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica



Scomposizione dello scarto quadratico medio (MSE)

$$MSE(\tilde{\beta}_j) \stackrel{\text{def}}{=} E\left((\tilde{\beta}_j - \beta_j)^2\right) = \underbrace{\left(E(\tilde{\beta}_j) - \beta_j\right)^2}_{\text{Bias}^2} + \underbrace{Var(\tilde{\beta}_j)}_{\text{Variance}}$$



Stima di Massima Verosimiglianza con Penalizzazione

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \left\{ D(\beta, \mathbf{y}) + \lambda \|\beta_{\setminus 0}\|_2^2 \right\}$$


dove

- $\|\beta_{\setminus 0}\|_2^2 = \sum_{j=1}^p \beta_j^2$
- $\lambda \geq 0$ iperparametro di penalizzazione


Modello sottostante: GLM




Regressione Ridge: esempio




(a) $\lambda = 0$




(b) $\lambda = 0.1$



(c) $\lambda = 1$



(d) $\lambda = 10$



Stima di Massima Verosimiglianza con Penalizzazione

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \left\{ D(\beta, \mathbf{y}) + \lambda \|\beta_{\setminus 0}\|_1 \right\}$$


dove

- $\|\beta_{\setminus 0}\|_1 = \sum_{j=1}^p |\beta_j|$
- $\lambda \geq 0$ iperparametro di penalizzazione


Modello sottostante: GLM




Regressione LASSO: esempio




(a) $\lambda = 0$




(b) $\lambda = 0.1$



(c) $\lambda = 1$



(d) $\lambda = 10$



Stima di Massima Verosimiglianza con Penalizzazione

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} \left\{ D(\boldsymbol{\beta}, \mathbf{y}) + \lambda \sum_{j=1}^p (\alpha |\beta_j| + (1 - \alpha) |\beta_j|^2) \right\}$$

dove

- $\|\boldsymbol{\beta}_{\setminus 0}\|_1 = \sum_{j=1}^p |\beta_j|$
- $\|\boldsymbol{\beta}_{\setminus 0}\|_2^2 = \sum_{j=1}^p \beta_j^2$
- $\lambda \geq 0$ iperparametro di penalizzazione
- $\alpha \in [0, 1]$ iperparametro che determina il peso della LASSO

Modello sottostante: GLM



1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)
 - Modelli Additivi Generalizzati (GAM)
 - Stimatori Shrinkage per i GLM
 - Stimatori Bayesiani per i GLM**
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica







Regressione Ridge e LASSO come Stimatori Bayesiani



Considerazioni sugli Stimatori Bayesiani



1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)
 - Modelli Additivi Generalizzati (GAM)
 - Stimatori Shrinkage per i GLM
 - Stimatori Bayesiani per i GLM
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica



Cenni sugli Algoritmi di Machine Learning



1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)
 - Modelli Additivi Generalizzati (GAM)
 - Stimatori Shrinkage per i GLM
 - Stimatori Bayesiani per i GLM
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica





1. Il Pricing nelle Assicurazioni Danni
2. Modelli Statistici per il Pricing nelle Assicurazioni Danni
 - Modelli Lineari Generalizzati (GLM)
 - Modelli Additivi Generalizzati (GAM)
 - Stimatori Shrinkage per i GLM
 - Stimatori Bayesiani per i GLM
 - Cenni sugli Algoritmi di Machine Learning
 - Confronto tra i modelli
3. Applicazione Pratica











