Application of GLM Advancements to Non-Life Insurance Pricing

Leonardo Stincone

Università degli Studi di Trieste

10 Maggio 2021

Contratto di Assicurazione, Art. 1882, Codice Civile Italiano

L'assicurazione è il contratto col quale l'**assicuratore**, verso il pagamento di un **premio**, si obbliga a rivalere l'**assicurato**, entro i limiti convenuti,

1. del **danno** ad esso prodotto da un **sinistro**,
2. ovvero a pagare un **capitale** o una **rendita** al verificarsi di un **evento** attinente alla **vita umana**.

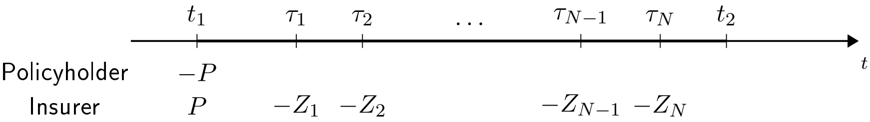

Distribuzione composta

Assumiamo che:

1. $\forall n > 0,\ Z_1|N = n,\ Z_2|N = n,\ \dots,\ Z_n|N = n$ siano i.i.d.;
2. la distribuzione di $Z_i|N = n,\ i \leq n$ non dipenda da n.

Sotto queste ipotesi diciamo che:

$$S = \begin{cases} 0 & \text{if } N = 0 \\ \sum_{i=1}^{N} Z_i & \text{if } N > 0 \end{cases}$$

ha distribuzione composta.

Proprietà

$$\begin{tikzcd} F_N \arrow[dr] & & F_Z \arrow[dl] \\ & F_S & \end{tikzcd}$$

$$E(S) = E(N)E(Z)$$

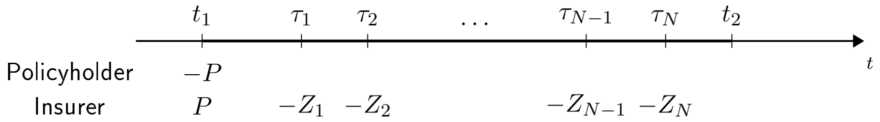

Distribuzione composta

Assumiamo che:

1. $\forall n > 0,\ Z_1|N = n,\ Z_2|N = n,\ \dots,\ Z_n|N = n$ siano i.i.d.;
2. la distribuzione di $Z_i|N = n,\ i \leq n$ non dipenda da n.

Sotto queste ipotesi diciamo che:

$$S = \begin{cases} 0 & \text{if } N = 0 \\ \sum_{i=1}^{N} Z_i & \text{if } N > 0 \end{cases}$$

ha distribuzione composta.

Proprietà

$$E(S) = E(N)E(Z)$$

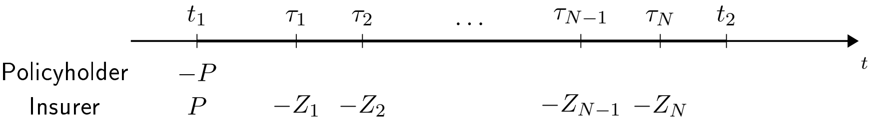

Distribuzione composta

Assumiamo che:

1. $\forall n > 0,\ Z_1|N = n,\ Z_2|N = n,\ \dots,\ Z_n|N = n$ siano i.i.d.;
2. la distribuzione di $Z_i|N = n,\ i \leq n$ non dipenda da n.

Sotto queste ipotesi diciamo che:

$$S = \begin{cases} 0 & \text{if } N = 0 \\ \sum_{i=1}^{N} Z_i & \text{if } N > 0 \end{cases}$$

ha distribuzione composta.

Proprietà

$$\begin{tikzcd} F_N \arrow[dr] & & F_Z \arrow[dl] \\ & F_S & \end{tikzcd}$$

$$E(S) = E(N)E(Z)$$

Personalizzazione e Variabili Esplicative

Variabili esplicative

Possibili variabili esplicative per il pricing delle assicurazioni motor:

- Informazioni sul veicolo assicurato;
- Informazioni generiche sul contraente;
- Informazioni assicurative sul contraente;
- Opzioni sulla polizza assicurativa;
- Dati telematici.

Queste variabili possono essere codificate come un vettore di numeri reali:

$$\boldsymbol{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip}) \in \mathcal{X} \subseteq \mathbb{R}^p$$

Regola di Pricing

Una *Regola di Pricing* è una funzione $f(\cdot)$ che da una $\boldsymbol{x}_i \in \mathcal{X}$ restituisce un prezzo P_i:

$$\begin{aligned} f: \quad \mathcal{X} &\longrightarrow R_+ \\ \boldsymbol{x}_i &\longmapsto P_i \end{aligned}$$

Modellare una variabile risposta

Modellare una variabile risposta Y_i significa stimare una funzione $r(\cdot)$ che da una $\boldsymbol{x}_i \in \mathcal{X}$ restituisce la distribuzione di Y_i o alcuni suoi momenti:

$$\begin{aligned} r: \quad \mathcal{X} &\longrightarrow \mathcal{C} \\ \boldsymbol{x}_i &\longmapsto F_{Y_i}, E(Y_i), Var(Y_i) \end{aligned}$$

Variabili esplicative

Possibili variabili esplicative per il pricing delle assicurazioni motor:

- Informazioni sul veicolo assicurato;
- Informazioni generiche sul contraente;
- Informazioni assicurative sul contraente;
- Opzioni sulla polizza assicurativa;
- Dati telematici.

Queste variabili possono essere codificate come un vettore di numeri reali:

$$\boldsymbol{x}_i = (x_{i1}, x_{i2}, \ldots, x_{ip}) \in \mathcal{X} \subseteq \mathbb{R}^p$$

Regola di Pricing

Una *Regola di Pricing* è una funzione $f(\cdot)$ che da una $\boldsymbol{x}_i \in \mathcal{X}$ restituisce un prezzo P_i:

$$\begin{array}{rccc} f: & \mathcal{X} & \longrightarrow & R_+ \\ & \boldsymbol{x}_i & \longmapsto & P_i \end{array}$$

Modellare una variabile risposta

Modellare una variabile risposta Y_i significa stimare una funzione $r(\cdot)$ che da una $\boldsymbol{x}_i \in \mathcal{X}$ restituisce la distribuzione di Y_i o alcuni suoi momenti:

$$\begin{array}{rccc} r: & \mathcal{X} & \longrightarrow & \mathcal{C} \\ & \boldsymbol{x}_i & \longmapsto & F_{Y_i}, E(Y_i), Var(Y_i) \end{array}$$

Distribuzione di Poisson

$$p_N(n) = P\left(N = n\right) = e^{-\lambda}\frac{\lambda^n}{n!}, \quad \lambda > 0$$

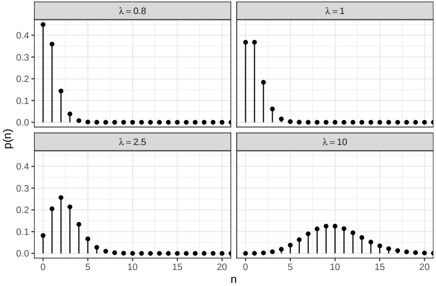

Distribuzione Gamma

$$f_Z(z) = \frac{\rho^\alpha}{\Gamma(\alpha)} z^{\alpha-1} e^{-\rho z}, \quad \alpha > 0, \ \rho > 0$$

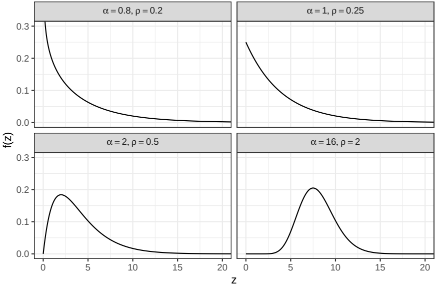

Definizione di Premio

$$P_i^{(\text{risk})} = E(S_i)$$
$$P_i^{(\text{tech})} = E(S_i) + \text{Expenses}_i$$

$\downarrow$

Altri Caricamenti
Vincoli Normativi
Commercializzazioni

$$P_i^{(\text{tariff})}$$
$$P_i^{(\text{offer})} = P_i^{(\text{tariff})} - \text{Discount}_i$$

Ottimizzazione del Prezzo

Si basa su

1. Pricing Tecnico
2. Aspettativa del Cliente
3. Strategia di Business

Ulteriori modelli

- New Business: Probabilità di Conversion
- Rinnovi: Probabilità di Retention

Definizione di Premio

$$P_i^{(\text{risk})} = E(S_i)$$
$$P_i^{(\text{tech})} = E(S_i) + \text{Expenses}_i$$

Altri Caricamenti
Vincoli Normativi
Commercializzazioni

$$P_i^{(\text{tariff})}$$
$$P_i^{(\text{offer})} = P_i^{(\text{tariff})} - \text{Discount}_i$$

Ottimizzazione del Prezzo

Si basa su

1. Pricing Tecnico
2. Aspettativa del Cliente
3. Strategia di Business

Ulteriori modelli

- New Business: Probabilità di Conversion
- Rinnovi: Probabilità di Retention

Modelli Lineari Generalizzati (GLM)

Dato $\mathcal{D} = \{(\boldsymbol{x}_1, \omega_1, y_1), \ldots, (\boldsymbol{x}_n, \omega_n, y_n)\}$
con $\boldsymbol{y} = (y_1, \ldots, y_n)^t$ realizzazione di $\boldsymbol{Y} = (Y_1, \ldots, Y_n)^t$.

Assumiamo che:

1. $\boldsymbol{Y} = (Y_1, \ldots, Y_n)^t$ siano indipendenti con distribuzione appartenente a una stessa famiglia esponenziale lineare:

$$f(y_i; \theta_i, \phi, \omega_i) = \exp\left\{\frac{\omega_i}{\phi}\left[y_i\theta_i - b(\theta_i)\right]\right\} c(y_i, \phi, \omega_i), \quad y_i \in \mathcal{Y} \subseteq \mathbb{R}$$

2. $\boldsymbol{x}_i = (1, x_{i1}, \ldots, x_{ip})^t$ agisca su Y_i tramite il predittore lineare η_i

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}$$

3. η_i sia legato a $\mu_i = E(Y_i)$ tramite la funzione legame $g(\cdot)$

$$g(\mu_i) = \eta_i = \boldsymbol{x}_i^t \boldsymbol{\beta}$$

Stima di massima verosimiglianza

Data la funzione di verosimiglianza

$$\begin{array}{rccc} L: & \mathbb{R}^{p+1} \times \Lambda & \longrightarrow & [0, +\infty[\\ & (\boldsymbol{\beta}, \phi) & \longmapsto & f_{\boldsymbol{Y}}(\boldsymbol{y}; \boldsymbol{\theta}, \phi) \end{array}$$

La stima di massima verosimiglianza è:

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta} \in \mathbb{R}^{p+1}}{\arg\max}\, L(\boldsymbol{\beta}, \phi; \boldsymbol{y})$$

Devianza

La devianza è

$$D(\hat{\boldsymbol{\beta}}, \boldsymbol{y}) = -2\phi\left(\ell\left(\hat{\boldsymbol{\beta}}, \phi; \boldsymbol{y}\right) - \ell_S(\boldsymbol{\beta}^*, \phi; \boldsymbol{y})\right)$$

dove $\ell\left(\hat{\boldsymbol{\beta}}, \phi; \boldsymbol{y}\right) = \log L\left(\hat{\boldsymbol{\beta}}, \phi; \boldsymbol{y}\right)$
e $\boldsymbol{\beta}^*$ sono i parametri del modello saturo.

La stima di massima verosimiglianza può essere ottenuta come:

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta} \in \mathbb{R}^{p+1}}{\arg\min}\, D(\boldsymbol{\beta}, \boldsymbol{y})$$

Stima di massima verosimiglianza

Data la funzione di verosimiglianza

$$\begin{array}{rccc} L: & \mathbb{R}^{p+1} \times \Lambda & \longrightarrow & [0, +\infty[\\ & (\boldsymbol{\beta}, \phi) & \longmapsto & f_{\boldsymbol{Y}}(\boldsymbol{y}; \boldsymbol{\theta}, \phi) \end{array}$$

La stima di massima verosimiglianza è:

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta} \in \mathbb{R}^{p+1}}{\arg\max}\, L(\boldsymbol{\beta}, \phi; \boldsymbol{y})$$

Devianza

La devianza è

$$D(\hat{\boldsymbol{\beta}}, \boldsymbol{y}) = -2\phi \left(\ell\left(\hat{\boldsymbol{\beta}}, \phi; \boldsymbol{y}\right) - \ell_S(\boldsymbol{\beta}^*, \phi; \boldsymbol{y}) \right)$$

dove $\ell\left(\hat{\boldsymbol{\beta}}, \phi; \boldsymbol{y}\right) = \log L\left(\hat{\boldsymbol{\beta}}, \phi; \boldsymbol{y}\right)$
e $\boldsymbol{\beta}^*$ sono i parametri del modello saturo.

La stima di massima verosimiglianza può essere ottenuta come:

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta} \in \mathbb{R}^{p+1}}{\arg\min}\, D(\boldsymbol{\beta}, \boldsymbol{y})$$

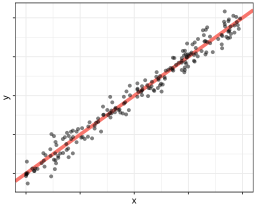

(a) Quantitativa

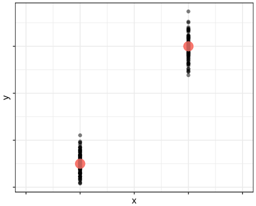

(b) Qualitativa

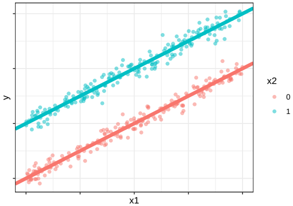

(c) Quantitativa e qualitativa senza interazione

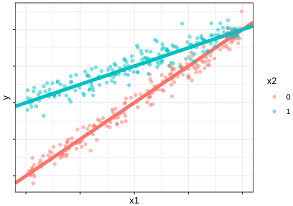

(d) Quantitativa e qualitativa con interazione

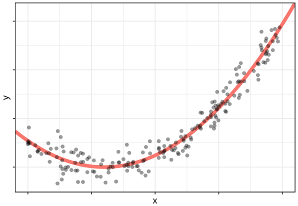

(a) Polynomial degree 2

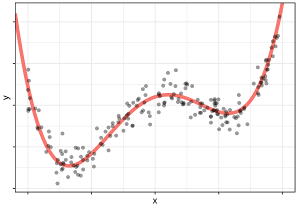

(b) Polynomial degree 4

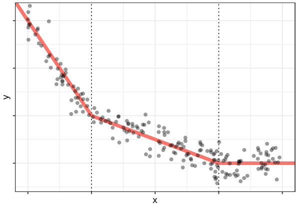

(c) Piece-wise linear

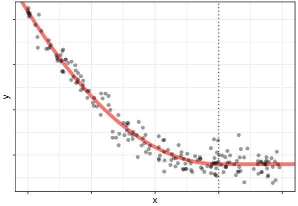

(d) Piece-wise polynomial degree 2

Funzione Legame e risposta

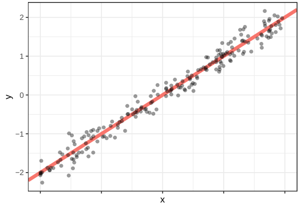

(a) Normal - identity

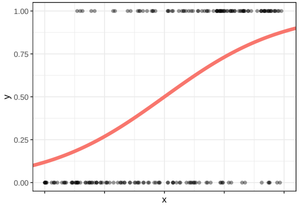

(b) Binomial - logit

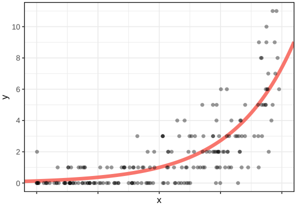

(c) Poisson - log

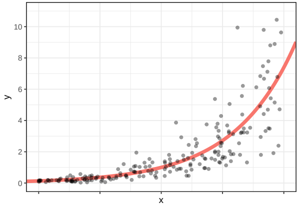

(d) Gamma - log

Grafici per visualizzare l'effetto delle variabili

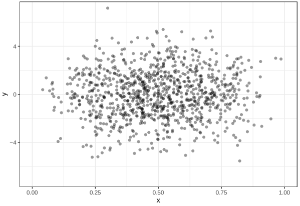

(a) No effect - ungrouped

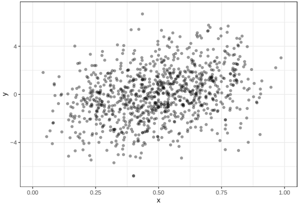

(b) Positive effect - ungrouped

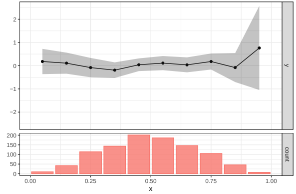

(c) No effect - grouped

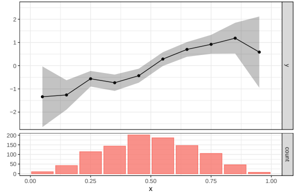

(d) Positive effect - grouped

Criteri per la selezione delle variabili

- Visualizzazione
- Test di verifica di ipotesi

$$\begin{cases} H_0: & \beta_{j_k} = 0 \ \forall k \in \{1, 2, \ldots, s\} \\ H_1: & \exists k : \beta_{j_k} \neq 0 \end{cases}$$

- Criteri di informazione

$$AIC = -2\ell(\boldsymbol{\beta}) + 2(p+1)$$
$$BIC = -2\ell(\boldsymbol{\beta}) + \log(n)(p+1)$$

- Divisione del dataset tra training set e test set
- Cross validation

$\Longrightarrow$ Algoritmi stepwise

Modello Additivo Generalizzato (GAM)

1. Variabile risposta $\boldsymbol{Y}$ come GLM;
2. Predittore lineare

$$\eta_i = \boldsymbol{x}_i^t \boldsymbol{\beta} + \sum_{l=1}^{q} f_l(z_{i,l}), \quad i \in \{1, 2, \ldots, n\}$$

   con $f_l(\cdot)$ spline cubica;
3. Funzione legame $g(\cdot)$ come GLM.

Stima di Massima Verosimiglianza con Penalizzazione

$$\hat{\boldsymbol{f}} = \arg\min_{\boldsymbol{f}} \left\{ D(\boldsymbol{f}, \boldsymbol{y}) + \sum_{l=1}^{q} \lambda_l \int_{a_l}^{b_l} \left(f_l''(x_l)\right)^2 dx \right\}$$

con $\lambda_1, \lambda_2, \ldots, \lambda_q$ iperparametri di smoothing.

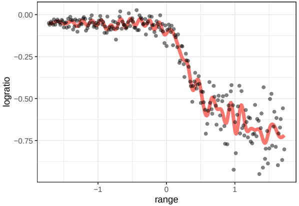

(a) $\lambda = 0$

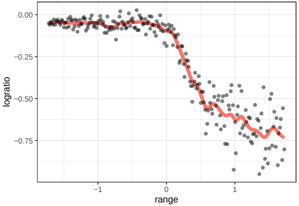

(b) $\lambda = 10$

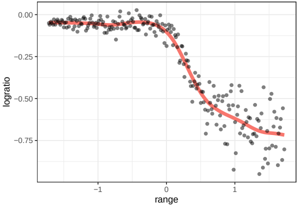

(c) $\lambda = 10^3$

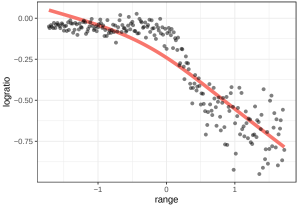

(d) $\lambda = 10^6$

Scomposizione dello scarto quadratico medio (MSE)

$$MSE\left(\tilde{\beta}_j\right) \stackrel{\text{def}}{=} E\left(\left(\tilde{\beta}_j - \beta_j\right)^2\right) = \underbrace{\left(E(\tilde{\beta}_j) - \beta_j\right)^2}_{\text{Bias}^2} + \underbrace{Var\left(\tilde{\beta}_j\right)}_{\text{Variance}}$$

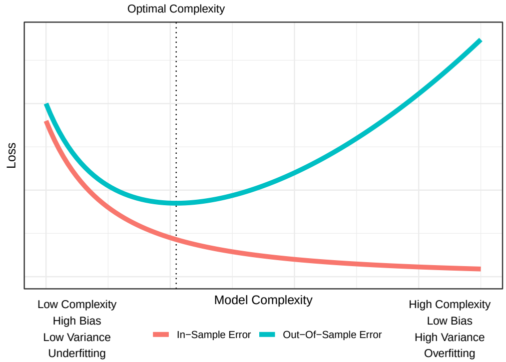

Modello sottostante:GLM

Stima di Massima Verosimiglianza con Penalizzazione

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta} \in \mathbb{R}^{p+1}}{\arg\min} \left\{ D(\boldsymbol{\beta}, \boldsymbol{y}) + \lambda \|\boldsymbol{\beta}_{\setminus 0}\|_2^2 \right\}$$

dove

- $\|\boldsymbol{\beta}_{\setminus 0}\|_2^2 = \sum_{j=1}^{p} \beta_j^2$
- $\lambda \geq 0$ iperparametro di penalizzazione

Regressione Ridge: esempio

Regressione LASSO: esempio

Titolo di prova

Titolo di prova capitolo 3

Titolo di prova capitolo 3